

Redes generativas para balanceo de fraude crediticio

Generación de transacciones sintéticas mediante una GAN

Resumen ejecutivo


El proyecto estudia un problema de fraude con desbalance extremo y compara estrategias para mejorar la representación de la clase minoritaria. Además de `class_weight`, submuestreo y SMOTE, se entrena una red generativa adversaria para producir 2.000 registros sintéticos. Los datos generados se incorporan al entrenamiento de Decision Tree, Random Forest y Gradient Boosting, observándose mejoras importantes en F1, precision y recall.

1. Objetivo

El objetivo es evaluar si la generación de observaciones sintéticas puede mejorar la detección de fraude frente a estrategias de balanceo más tradicionales. La comparación se centra en el efecto de cada configuración sobre F1, precision y recall, métricas adecuadas para un problema donde la clase positiva es muy escasa.


2. Datos y desbalance

La base contiene 284.807 transacciones y 31 variables. Solo 492 operaciones corresponden a fraude, mientras que 284.315 son legítimas. La proporción de fraude es 0,17%, por lo que un modelo puede alcanzar una accuracy aparente muy elevada y, al mismo tiempo, fallar en la detección de la clase relevante.



Distribución de clases en la base completa.

El preprocesamiento mezcla las observaciones y normaliza las columnas al intervalo [0, 1]. Para parte de la experimentación se construye una muestra con 1.968 registros no fraudulentos y 492 fraudulentos, equivalente a una proporción 80/20.



Muestra de trabajo con mayor representación de la clase fraude.

3. Estrategias de tratamiento del desbalance

3.1 Class weight


La opción `class_weight="balanced"` aumenta el peso de los errores cometidos sobre la clase minoritaria. En Decision Tree el F1 desciende respecto de la configuración sin pesos, mientras que en Random Forest aumenta levemente y la precisión alcanza 1,0, manteniéndose el recall en 0,8537.

3.2 Submuestreo aleatorio

El submuestreo reduce la cantidad de observaciones de la clase mayoritaria para construir un conjunto más equilibrado. La ventaja es disminuir el sesgo hacia la clase no fraude; la desventaja es descartar información potencialmente útil sobre operaciones legítimas.

3.3 SMOTE

SMOTE genera observaciones sintéticas mediante interpolación entre vecinos de la clase minoritaria. En la muestra utilizada, el procedimiento produce 1.968 observaciones por clase. A diferencia de la GAN, SMOTE opera directamente en el espacio de variables sin entrenar un generador adversario.



Distribución equilibrada después de aplicar SMOTE.

4. Arquitectura de la GAN

Una GAN está formada por dos redes que se entrenan de manera adversaria. El generador recibe ruido aleatorio y produce registros con la misma cantidad de columnas que la base. El discriminador recibe datos reales y sintéticos e intenta identificar su procedencia. El generador mejora cuando logra producir observaciones que el discriminador clasifica como reales.

4.1 Generador

Se prueban dimensiones de ruido de 15 y 20. La arquitectura principal utiliza una capa Dense de 65 unidades con activación sigmoide y una salida de 31 unidades, también sigmoide, para reproducir las variables normalizadas. El resumen del modelo registra 3.411 parámetros entrenables.

4.2 Discriminador

El discriminador recibe 31 variables, utiliza una capa Dense de 64 unidades con activación sigmoide y una salida de una unidad. Se compila con binary crossentropy y Adam. El modelo registra 2.113 parámetros entrenables.

4.3 Entrenamiento adversario

1. Se fijan 50 épocas y batch size 64.
2. Cada batch combina fraude real y no fraude real, con reposición, para formar la mitad de los ejemplos.
3. El generador produce la otra mitad de datos sintéticos a partir de ruido normal.
4. Las etiquetas reales se suavizan a 0,9 y las sintéticas se etiquetan como 0.
5. Se actualiza el discriminador con datos reales y sintéticos.
6. Luego se congela el discriminador dentro del modelo adversario y se actualiza el generador para que sus registros sean clasificados como reales.

Después de experimentar con distintas dimensiones de ruido y configuraciones, se generan 2.000 transacciones sintéticas orientadas a ampliar la clase fraude. Esos registros se incorporan al conjunto de entrenamiento y se vuelven a evaluar los clasificadores.

5. Modelos de clasificación

- Decision Tree: referencia interpretable basada en reglas.
- Random Forest: ensamble de árboles con alta robustez y baja varianza relativa.
- Gradient Boosting: ensamble secuencial que corrige errores de modelos anteriores.

La división entrenamiento/prueba es 50/50, estratificada y con random_state=42. La comparación incluye modelos sin balanceo adicional, configuraciones con class_weight y modelos entrenados con 2.000 observaciones generadas por la GAN.

6. Resultados

Modelo	Configuración	F1	Precision	Recall
Decision Tree	Sin class_weight	0.8729	0.8802	0.8659
Decision Tree	Con class_weight	0.8468	0.84	0.8537
Decision Tree	Con GAN (2000 datos)	0.9707	0.9696	0.9719
Random Forest	Sin class_weight	0.919	0.9952	0.8537
Random Forest	Con class_weight	0.9211	1.0	0.8537
Random Forest	Con GAN (2000 datos)	0.985	0.9959	0.9743
Gradient Boosting	Sin class_weight	0.9126	0.9596	0.8699
Gradient Boosting	Con GAN (2000 datos)	0.983	0.9902	0.9759

7. Interpretación de resultados

Los tres clasificadores mejoran al incorporar los datos generados. Decision Tree pasa de F1 0,8729 a 0,9707. Random Forest alcanza el mejor F1 global, 0,9850, con precision 0,9959 y recall 0,9743. Gradient Boosting obtiene F1 0,9830 y el recall más alto, 0,9759.

La mejora del recall es especialmente relevante: los modelos con GAN detectan una proporción considerablemente mayor de operaciones fraudulentas. Al mismo tiempo, la precision permanece cercana a 1, lo que limita el crecimiento de falsas alertas en la muestra evaluada.

El class_weight no produce una mejora uniforme. En Random Forest incrementa levemente el F1, pero no modifica el recall. En Decision Tree, el F1 cae. Esto muestra que el efecto del balanceo depende de la interacción entre el algoritmo, la muestra y los hiperparámetros.

8. Limitaciones y controles necesarios

- Los datos sintéticos deben evaluarse por similitud estadística, diversidad y ausencia de duplicación de registros reales.
- La GAN y los clasificadores deben entrenarse sin acceder al conjunto final de prueba para evitar fuga de información.
- Un buen desempeño del clasificador no prueba por sí solo que los datos generados sean realistas.
- La validación debe repetirse sobre la distribución completa, donde el fraude vuelve a representar 0,17%.
- Conviene comparar contra SMOTE, ADASYN y métodos específicos para anomalías bajo el mismo protocolo.
- En aplicaciones reales deben considerarse privacidad, explicabilidad, monitoreo de drift y costo de falsas alertas.

9. Conclusión

La generación sintética mediante GAN resulta la estrategia con mayor mejora en la comparación realizada. Random Forest con GAN presenta el mejor equilibrio entre F1, precision y recall, mientras que Gradient Boosting alcanza un recall apenas superior. El resultado demuestra el potencial de las redes generativas para ampliar clases minoritarias, pero su uso operativo requiere controles adicionales sobre calidad, estabilidad y generalización.

Fuentes de datos y herramientas

- **Credit Card Fraud Detection**: base de transacciones europeas incluida en data/.
- [TensorFlow y Keras](#): implementación del generador, discriminador y modelo adversario.
- [imbalanced-learn](#): submuestreo y SMOTE.
- [Scikit-learn](#): clasificadores y métricas.
- **Código y resultados del proyecto**: notebook, figuras y tabla comparativa incluidos en el repositorio.